

Disciplina: Inteligência Artificial Computacional

Lara Stephanny Lima Gomes - 2410494 | André Lima Moraes - 2410378

Centro de Ciências Tecnológicas – Universidade de Fortaleza (UNIFOR)

Setembro de 2026

Resumo

Este relatório apresenta a implementação de modelos de regressão linear simples e múltipla em Python. Foram analisados dois problemas: a previsão da concentração de arsênio nas unhas do pé a partir de dados de exposição à água contaminada, e a previsão da dose de radiação em inspeções de raios X com base na corrente e no tempo de exposição. Os modelos foram avaliados pelas métricas R^2 , R^2 ajustado, MSE, RMSE e MAE, e as suposições do modelo foram verificadas por meio de análise de resíduos.

1 Introdução

A aplicação de modelos de regressão linear permite prever variáveis contínuas a partir de bases de dados observacionais. Este relatório tem como objetivo avaliar o desempenho de algoritmos de regressão implementados manualmente em Python.

No Problema 1, avaliamos concentrações de arsênio em unhas como indicadores de ingestão de água contaminada, com base em um estudo piloto publicado na revista *Cancer Epidemiology, Biomarkers and Prevention* (1996). No Problema 2, estudamos o efeito da inspeção de raios X em circuitos integrados, prevendo a dose de radiação com base na corrente e no tempo de exposição, dados de um artigo da revista *Electronic Packaging and Production* (2002).

2 Fundamentação Teórica

2.1 Regressão Linear Simples

A regressão linear simples modela a relação entre uma única variável independente e uma variável dependente contínua:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Neste modelo, a variável resposta Y varia em função da variável preditora X , sendo essa relação ponderada pelo coeficiente angular β_1 , que representa a inclinação da reta. A isso soma-se o β_0 (intercepto), que é o valor esperado de Y quando X é zero, e o erro aleatório ε .

Os coeficientes da regressão simples são estimados por:

$$\beta_1 = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \beta_0 = \bar{y} - \beta_1 \bar{x}$$

2.2 Regressão Linear Múltipla

A regressão linear múltipla expande o modelo simples ao utilizar duas ou mais variáveis independentes para explicar a variabilidade da resposta Y :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon$$

É a mesma equação da regressão linear simples, mas com mais variáveis independentes. Os coeficientes são estimados por mínimos quadrados, que em forma matricial pode ser escrito como:

$$\boldsymbol{\beta} = (X^T X)^{-1} X^T \mathbf{y}$$

Na prática, utilizamos a pseudoinversa de Moore-Penrose (`pinv`) para evitar problemas quando a matriz $X^T X$ não é invertível.

2.3 Interpretação dos Coeficientes e do Intercepto

O intercepto (β_0) é o valor esperado de Y quando todas as variáveis preditoras (X) forem iguais a zero. Já os coeficientes angulares (β_i) representam a variação de Y para cada alteração de uma unidade de X_i , mantendo as demais variáveis constantes. Por exemplo, a cada 1 ano de idade a mais, espera-se que a concentração de arsênio nas unhas varie em β_1 ppm, mantendo o uso da água e o arsênio na água constantes.

2.4 Métricas de Avaliação do Modelo

2.4.1 Coeficiente de Determinação (R^2)

Com ele, medimos a proporção da variância total de Y que é explicada pelo modelo:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Pode ir de 0 a 1, em que 0 indica que quase nada foi explicado pelo modelo e 1 indica que quase toda a variância dos dados foi explicada.

2.4.2 Coeficiente de Determinação Ajustado (R_{adj}^2)

O R^2 tende a aumentar sempre que uma nova variável é adicionada, mesmo que essa variável seja irrelevante. O R^2 ajustado penaliza o modelo pela inclusão de preditores desnecessários:

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

onde n é o número de observações e p é o número de preditores (sem contar o intercepto).

2.4.3 Raiz do Erro Quadrático Médio (RMSE)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

O RMSE penaliza os erros maiores de forma mais severa e traz a métrica de erro de volta para a mesma unidade da variável dependente (Y). Quanto menor, mais próximas as previsões estão dos valores reais.

2.4.4 Erro Absoluto Médio (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

O erro absoluto médio mede a magnitude média dos erros do modelo em termos absolutos. Diferente do RMSE, é menos sensível a *outliers*, e quanto menor, mais próximas as previsões estão dos valores reais.

3 Protocolo Experimental

3.1 Fonte dos Dados

Os datasets usados: `arsenio_dataset.csv` e `dose_radiacao_expandido.csv`, disponibilizados no AVA.

3.2 Variáveis dos Modelos

Problema 1: Idade, uso de água para beber, uso para cozinhar e arsênio na água como regressores, e arsênio nas unhas como variável dependente.

Problema 2: Corrente (mA) e tempo de exposição (min) como regressores, e dose de radiação (rad) como variável dependente.

3.3 Ferramentas

A implementação foi feita 100% em Python, utilizando as bibliotecas `numpy` (cálculos matriciais e métricas) e `matplotlib` (gráficos). Os modelos foram implementados manualmente por meio de classes, com a classe `MRegression` (regressão múltipla, via pseudoinversa de Moore-Penrose) e a classe `LinearRegression` (regressão simples, pelas fórmulas dos mínimos quadrados).

3.4 Passos para o Ajuste do Modelo

1. Leitura dos dados com `np.loadtxt`;
2. Separação das variáveis regressores (X) e da variável resposta (y);
3. Ajuste do modelo pelo método `fit()` (cálculo dos coeficientes β);
4. Cálculo dos valores ajustados $\hat{y}_i$ e dos resíduos $e_i = y_i - \hat{y}_i$;
5. Verificação das suposições do modelo por análise de resíduos (resíduos vs. valores ajustados, resíduos vs. ordem das observações e Q-Q plot);
6. Avaliação pelas métricas R^2 , R^2 ajustado, MSE, RMSE e MAE;
7. Comparação com modelo alternativo mais simples e com modelo de intercepto forçado a zero.

4 Resultados e Discussão

4.1 Problema 1: Arsênio nas Unhas

4.1.1 Modelo Completo (item a)

O modelo ajustado com os quatro regressores foi:

$$\hat{y} = 0,4875 - 0,0008 X_{idade} - 0,0227 X_{beber} - 0,0415 X_{cozinhar} + 13,2400 X_{arsênio}$$

O único coeficiente com magnitude relevante é o do arsênio na água: para cada aumento de 1 ppm de arsênio na água, espera-se um aumento de aproximadamente 13,24 ppm nas unhas, mantendo as demais variáveis constantes. Os coeficientes de idade, uso para beber e uso para cozinhar ficaram próximos de zero.

Tabela 1: Coeficientes estimados do modelo completo – Problema 1.

Coeficiente	Valor
Intercepto (β_0)	0,487508
Idade (β_1)	−0,000767
Uso para beber (β_2)	−0,022739
Uso para cozinhar (β_3)	−0,041504
Arsênio na água (β_4)	13,240010

4.1.2 Previsão (item b)

Para uma pessoa de 30 anos, com categoria 5 para beber e cozinhar e arsênio na água de 0,135 ppm, o modelo prevê:

$$\hat{y} = 1,9307 \text{ ppm}$$

4.1.3 Avaliação do Modelo (itens d e e)

Tabela 2: Métricas do modelo completo – Problema 1.

Métrica	Valor
R^2	0,8120
R^2 ajustado	0,7650

Muitos usuários de regressão preferem o R^2 ajustado porque o R^2 comum nunca diminui quando adicionamos variáveis ao modelo, mesmo que sejam irrelevantes. O R^2 ajustado corrige isso, penalizando o número de preditores.

No nosso caso, o R^2 ajustado (**0,7650**) foi **pior** que o R^2 comum (0,8120). Isso aconteceu porque temos poucas observações ($n = 21$) para muitos regressores ($p = 4$): a penalização por complexidade foi forte, indicando que as variáveis extras (idade, uso para beber e cozinhar) não agregaram tanta explicação assim.

4.1.4 Comparação com o Modelo Alternativo (item f)

O modelo alternativo, usando apenas o arsênio na água como preditor, foi:

$$\hat{y} = 0,1550 + 12,9856 X_{\text{arsênio}}$$

Embora o modelo completo tenha R^2 e RMSE levemente melhores, o modelo alternativo apresentou R^2 **ajustado superior** (0,7932 contra 0,7650). Como as métricas de erro são muito próximas, concluímos que o arsênio na água sozinho já explica bem a variável

Tabela 3: Comparação de métricas entre os modelos – Problema 1.

Métrica	Modelo Completo	Modelo Alternativo
R^2	0,8120	0,8036
R^2 ajustado	0,7650	0,7932
MSE	0,0424	0,0443
RMSE	0,2060	0,2106
MAE	0,1157	0,1334

resposta, e as demais variáveis agregam pouco. Pelo critério da parcimônia, o modelo simples é preferível neste caso.

4.1.5 Análise de Resíduos (item f)

A Tabela 4 apresenta os valores observados, ajustados e os resíduos $e_i = y_i - \hat{y}_i$ para as 21 observações.

Na Figura 1, o gráfico de resíduos vs. valores ajustados mostra os pontos dispersos em torno de zero, sem padrão definido, o que é desejável. Porém, observam-se alguns pontos com resíduos grandes (observações 6, 14 e 15), ligados às maiores concentrações de arsênio na água, que se comportam como possíveis *outliers*. O Q-Q plot indica aproximada normalidade dos resíduos, com leve desvio nas caudas. O gráfico de resíduos vs. ordem não apresenta tendência, sugerindo independência.




Figura 1: Análise de resíduos do modelo completo – Problema 1.

4.1.6 Intercepto Forçado a Zero (item g)

Impor intercepto zero significa assumir, por razões teóricas, que se todos os regressores forem zero (sem arsênio na água e sem uso do poço), a concentração de arsênio nas unhas também será zero. Do ponto de vista prático e biológico, essa hipótese faz sentido, pois sem exposição não haveria acúmulo.

O modelo com intercepto teve desempenho melhor nas duas métricas, então o escolhemos. Além disso, os dados indicam que mesmo sem arsênio na água há uma concentração

Tabela 4: Tabela de resíduos do modelo completo – Problema 1.

Obs. i	y_i observado	$\hat{y}_i$ ajustado	e_i resíduo
1	0,119	0,144063	−0,025063
2	0,118	0,157297	−0,039297
3	0,099	0,132545	−0,033545
4	0,118	0,176375	−0,058375
5	0,277	0,206130	0,070870
6	0,358	0,131778	0,226222
7	0,080	0,131965	−0,051965
8	0,158	0,169021	−0,011021
9	0,310	0,310000	0,000000
10	0,105	0,151449	−0,046449
11	0,073	0,111069	−0,038069
12	0,832	0,831773	0,000227
13	0,517	0,382498	0,134502
14	2,252	1,914213	0,337787
15	0,851	0,443492	0,407508
16	0,269	0,373449	−0,104449
17	0,433	1,144081	−0,711081
18	0,141	0,117972	0,023028
19	0,275	0,352539	−0,077539
20	0,135	0,120328	0,014672
21	0,175	0,192965	−0,017965

residual nas unhas (alimentos, outros fatores), o que justifica um intercepto diferente de zero.

4.1.7 Outras Métricas de Erro (item h)

Além do R^2 , utilizamos o MSE, RMSE e MAE (Tabela de comparação acima, no item f). O MAE de 0,1157 ppm do modelo completo indica que, em média, o erro absoluto das previsões é de aproximadamente 0,12 ppm, um valor pequeno se comparado à faixa de variação dos dados.

4.2 Problema 2: Dose de Radiação

4.2.1 Modelo Completo (item a)

$$\hat{y} = -433,8145 + 17,9035 X_{corrente} + 69,5791 X_{tempo}$$

O coeficiente do tempo de exposição é bem maior que o da corrente: cada minuto

Tabela 5: Comparação entre modelo com e sem intercepto – Problema 1.

Modelo	R^2	RMSE
Com intercepto	0,8120	0,2060
Intercepto zero	0,7967	0,2142

Tabela 6: Coeficientes estimados do modelo completo – Problema 2.

Coeficiente	Valor
Intercepto (β_0)	-433,814457
Corrente, mA (β_1)	17,903524
Tempo de exposição, min (β_2)	69,579075

a mais de exposição aumenta a dose em cerca de 69,58 rad, contra 17,90 rad para cada miliampère a mais.

4.2.2 Previsão (item b)

Para corrente de 15 mA e tempo de exposição de 5 minutos, o modelo prevê:

$$\hat{y} = 182,63 \text{ rad}$$

4.2.3 Avaliação do Modelo (itens c e d)

Tabela 7: Métricas do modelo completo – Problema 2.

Métrica	Valor
R^2	0,8431
R^2 ajustado	0,8425

O R^2 ajustado praticamente não caiu em relação ao R^2 comum (0,8425 contra 0,8431). Isso ocorre porque temos muitas observações ($n = 540$) e poucos preditores ($p = 2$), então a penalização por complexidade é desprezível e as variáveis adicionadas são claramente justificadas.

4.2.4 Comparação com o Modelo Alternativo (item e)

O modelo alternativo, usando apenas a corrente como preditor, foi:

$$\hat{y} = 91,1745 + 15,2476 X_{\text{corrente}}$$

Tabela 8: Comparação de métricas entre os modelos – Problema 2.

Métrica	Modelo Completo	Modelo Alternativo
R^2	0,8431	0,0807
R^2 ajustado	0,8425	0,0790
MSE	54530,07	319495,33
RMSE	233,52	565,24
MAE	187,59	464,26

O modelo completo é **muito superior** em todas as métricas. Sozinha, a corrente explica apenas cerca de 8% da variância da dose ($R^2 = 0,0807$), e o RMSE cai de 565,24 para 233,52 rad quando o tempo de exposição entra no modelo. O tempo de exposição é, portanto, o fator dominante na determinação da dose.

4.2.5 Intercepto Forçado a Zero (item f)

Teoricamente, com corrente zero e tempo zero a dose deveria ser zero. Forçando o intercepto a zero, obtemos:

Tabela 9: Comparação entre modelo com e sem intercepto – Problema 2.

Modelo	R^2	RMSE
Com intercepto	0,8431	233,52
Intercepto zero	0,7631	286,92

Novamente o modelo com intercepto foi superior. Embora a interpretação física do intercepto zero seja atraente, os dados mostram que o ajuste fica pior sem ele, provavelmente porque a relação não é perfeitamente linear na faixa de baixas doses.

4.2.6 Outras Métricas de Erro (item h)

As métricas MSE, RMSE e MAE estão na Tabela de comparação do item e. O RMSE de 233,52 rad significa que, em média, as previsões do modelo completo erram por volta de 234 rad. Como as doses variam de 7,4 a 2368 rad, esse erro é aceitável, mas mostra que ainda há variabilidade não explicada, principalmente nas doses mais altas, como visto no gráfico de resíduos da Figura 2.

Na Figura 2, o hiperplano ajustado segue bem a nuvem de pontos, e o gráfico de observado vs. previsto mostra os pontos próximos da reta $y = x$, confirmando a boa adequação do modelo. O gráfico de resíduos vs. ajustados apresenta dispersão em torno de zero, sem padrão sistemático evidente.




Figura 2: Hiperplano de regressão, resíduos e valores observados vs. previstos – Problema 2.

5 Conclusão

Neste trabalho, implementamos modelos de regressão linear simples e múltipla manualmente em Python e os aplicamos a dois problemas reais.

No Problema 1 (arsênio), o modelo completo obteve $R^2 = 0,8120$, mas o R^2 ajustado caiu para 0,7650, sinal de que as variáveis extras não compensam sua complexidade. O modelo apenas com o arsênio na água teve R^2 ajustado maior (0,7932), sendo o escolhido pela parcimônia. A análise de resíduos indicou boa adequação, com alguns possíveis *outliers* nas maiores concentrações.

No Problema 2 (radiação), o modelo completo com corrente e tempo foi claramente superior ($R^2 = 0,8431$, RMSE = 233,52 rad), enquanto a corrente sozinha explicava apenas 8% da variância. O tempo de exposição é o preditor mais importante.

Em ambos os problemas, o modelo com intercepto superou o modelo de intercepto zero, mostrando que os dados não sustentam a restrição teórica.

Como melhorias futuras, seria interessante aplicar transformações nas variáveis (por exemplo, logaritmo) para reduzir a influência dos *outliers* no Problema 1, e avaliar a possibilidade de incluir um termo de interação (corrente $\times$ tempo) no Problema 2.